

1. Objetivo do projeto

O objetivo do projeto foi construir um sistema agêntico de QA jurídico, robusto e auditável, para responder a perguntas sobre legislação portuguesa dos jogos e apostas online, garantindo que:

- As respostas são estritamente baseadas no texto legal;
- Não há alucinação jurídica;
- Perguntas fora do domínio são corretamente filtradas;
- Perguntas de lookup textual (ex.: “qual é a redação da alínea x) do artigo y.º”) são tratadas de forma determinística;
- Perguntas interpretativas ou temáticas continuam a funcionar corretamente.

2. Visão geral da pipeline (end-to-end)

A pipeline implementada segue um modelo agêntico com *LangGraph*, integrando *LlamaIndex* para retrieval e *LlangSmith* para observabilidade e um LLM apenas onde é estritamente necessário.

Fluxo de alto nível:

1. Ingestão e preparação dos documentos;
2. Indexação semântica + lexical;
3. Domain gating;
4. Decisão de retrieval;
5. Retrieval determinístico ou híbrido;
6. Classificação de relevância (chunk grading);
7. Geração da resposta grounded;
8. Reflexão e autocorreção;
9. Resposta final ao utilizador.

3. Preparação e indexação dos documentos

3.1 Ingestão

- PDFs são carregados com *PyMuPDFReader* para evitar corrupção de texto
- Metadados legais são adicionados manualmente (fonte, versão, jurisdição)

3.2 Limpeza jurídica do texto

Foram removidos:

- Numeração de páginas (“28 de 59”, “Pág. 36 de 59”);
- Cabeçalhos repetidos do Diário da República;
- Quebras artificiais excessivas.

Isto foi essencial para evitar falsos negativos no retrieval e garantir coerência na detecção de artigos e alíneas.

3.3 *Chunking* por artigo (decisão crítica)

Em vez de *chunking* arbitrário, o texto foi dividido por artigo, garantindo que cada node corresponde a uma unidade jurídica lógica. Assim, *lookup* por “Artigo Y.º” é possível e determinístico e, além disso, não se perde contexto normativo relevante.

4. Estratégia de *retrieval* (um dos pontos mais críticos)

4.1 Índices utilizados

O sistema usa *retrieval* híbrido, sem LLM no *retrieval*:

- *Vector retrieval* (*embeddings* multilingual-e5)
- BM25 lexical retrieval

4.2 Retrieval determinístico por artigo

Se a pergunta contém: “Artigo Y” o sistema ignora *embeddings* e BM25 e faz *lookup* direto por: `metadata["artigo"] == N`.

Isto resolve completamente falhas de *embedding* em perguntas jurídicas formais e ambiguidade em pedidos de redação exata de determinado artigo ou alínea.

4.3 *Retrieval* híbrido (*fallback*)

Para perguntas temáticas (ex.: autoexclusão):

- Combina resultados do vector *retriever* e BM25;
- Normaliza scores;
- Funde resultados de forma determinística;
- Sem dependência de *OpenAI* ou *LLMs* no *retrieval*.

5. Domain Gate

Antes de qualquer *retrieval*, o sistema avalia se a pergunta é:

- *fora_do_dominio* → resposta direta conversacional
- *potencialmente_documental* → pipeline jurídico completa

Isto evita: Custos desnecessários, respostas jurídicas para perguntas irrelevantes e ruído no grafo

6. Decisão de uso de ferramentas (*retrieval_decider*)

Um nó LLM decide:

- Se consegue responder diretamente
- Ou se precisa de chamar a *tool* de *retrieval*

Este nó não responde juridicamente — apenas decide.

7. Grade *chunks* (avaliação de aplicabilidade)

Este foi um dos maiores desafios do projeto.

7.1 Problema inicial

- O LLM rejeitava *chunks* corretos porque:
 - Não “via” explicitamente a alínea pedida;
 - Ou o *chunk* continha mais texto do que o esperado.

7.2 Solução final (robusta)

Foram introduzidas duas lógicas complementares:

A) *Lookup* textual (*bypass* total do *grading*)

Se a pergunta é do tipo:

- “Qual é a redação...” ou “O que diz o artigo...”

Então:

- O *grading* é ignorado;
- Todos os *chunks* do artigo correto são considerados aplicáveis;
- Se houver alínea, tenta-se localizar;
- Se não localizar, mantém-se o artigo como aplicável.

B) *Grading* normal (LLM)

Para perguntas interpretativas:

- Cada *chunk* é avaliado como aplicável ou não;
- Com justificação;
- Mantém controlo fino sobre contexto usado.

8. Geração da resposta (*grounded*)

A geração é estritamente condicionada ao contexto selecionado.

Existem dois modos:

8.1 *Lookup* textual com alínea

Prompt especial que exige transcrição fiel, sem paráfrase e sem conhecimento externo.

Se a alínea não estiver visível o sistema declara explicitamente a limitação e nunca inventa texto.

8.2 Resposta jurídica geral

- Apenas com base no contexto;
- Se algo não constar -> o modelo deve dizê-lo explicitamente.

9. *Reflection* (*self-check* jurídico)

Antes da resposta final um nó de revisão jurídica valida se todas as afirmações estão suportadas pelo contexto se não estiverem a resposta é corrigida ou substituída por:

“O documento não contém informação suficiente para responder a esta pergunta.”

Este passo elimina:

- *Over-reach* do modelo;
- Inferências não sustentadas;
- Risco jurídico.

10. Principais desafios enfrentados e resolvidos

10.1 *Chunking* inadequado

Problema: *chunks* demasiado pequenos ou arbitrários.

Solução: *chunking* por artigo.

10.2 Falhas de *retrieval* em *lookup* jurídico

Problema: *embeddings* falhavam em “Artigo Y.º, alínea x)”.

Solução: *lookup* determinístico por metadata.

10.3 Rejeição indevida de *chunks* corretos

Problema: *grading* demasiado agressivo.

Solução: *bypass* completo para *lookup* textual.

10.4 Dependência implícita de OpenAI

Problema: BM25 / QueryFusion acionava LLMs internamente.

Solução: *hybrid retrieval* manual, sem LLM.

10.5 Alucinação em geração

Problema: respostas “bem escritas”, mas não sustentadas.

Solução: *reflection* node obrigatório, com contexto suportado nos documentos legais.